6 Codeoptimierung

Dieser Abschnitt ist eine kurze Einführung in die prinzipielle Vorgehensweise bei der Codeoptimierung. Ziel der Codeoptimierung ist die Umformung eines Zwischencode-Programms in ein kürzeres oder schnelleres, aber funktional äquivalentes Programm. Der Begriff „Codeoptimierung“ ist dabei eigentlich irreführend, denn Aho, Johnson und Ullman zeigten in [21], dass eine optimale Code-Erzeugung für eine hypothetische Maschine mit einer noch einfacheren Struktur als die einer Drei-Adress-Code verarbeitenden Maschine, bereits NP-vollständig ist.

6.1 Einführung

Ansatzpunkt für die Optimierung sind die Rümpfe innerer Schleifen, denn nach der bekannten 80-20 Regel werden etwa 80% der Zeit in 20% des Codes verbraucht. Es ist sicherlich nicht sinnvoll, auf den nur einmal durchlaufenen Initialisierungsteil eines Programms eine komplizierte und aufwändige Optimierung anzusetzen.
Forderungen an die zur Codeoptimierung benutzten Programmtransformationen:

1) Eine Programmtransformation darf die Funktion eines Programms nicht ändern. Das ist einleuchtend für das Input/Output Verhalten, schwieriger wird es schon bei Laufzeitfehlern. Ein zurückhaltendes Vorgehen bei der Codeoptimierung ist aber wichtig.

2) Eine angewendete Programmtransformation sollte, zumindest im Mittel, die Laufzeit des Programms messbar verringern.

3) Eine Programmtransformation sollte kosteneffektiv sein, d.h. der Kostenaufwand sollte in vernünftiger Relation zur Verbesserung der Laufzeit des Programms stehen. Es daher ist wenig sinnvoll, komplizierte Codeoptimierungen auf Programme anzuwenden, die nur ein paar mal aufgerufen werden.

Um ein wenig in die Problematik einzuführen betrachten wir zunächst das folgende Beispiel (nach [23]), das die Problematik von Programmtransformationen zeigt.

Beispiel 6.1:
Betrachten wir zunächst das folgende Ausgangsprogramm mit `n`$\leq$`m` und `k`$\leq$`m`.

```
subroutine tricky (a, b, n, m, k);
integer i, n, m, k;
int a[m], b[m];
for i := 1 to n do
    a[i] := b[k] + a[i] + 100000;
end;
```

Wie man sofort sieht, gibt es eine „schleifeninvariante Berechnung“ , d.h. eine Berechnung, die bei jedem Durchlauf durch die Schleife den gleichen Wert liefert. Zieht man diese Berechnung vor die Schleife, so erhält man:

```
subroutine tricky (a, b, n, m, k);
integer i, n, m, k;
int a[m], b[m], C;
C := b[k] + 100000;
for i := 1 to n do
    a[i] := a[i] + C;
end;
```

und man kann vermuten, dass dieses Programm schneller läuft, da der Term `b[k] + 100000` nur einmal ausgewertet werden muss.
Diese harmlos aussehende Änderung hat nun aber folgende Konsequenzen:

1) Es kann sein, dass im Originalprogramm alles richtig läuft, während im transformierten Programm ein Überlauf signalisiert wird! Der Term `b[k] + 100000` kann für die Integerdarstellung zu groß sein, während etwa die Berechnung von `b[k] + a[i] + 100000` durchaus Ergebnisse im Darstellungsbereich liefern kann. Erschwerend kommt hinzu, dass ein derartiger Überlauf *vor* Eintritt in die Schleife gemeldet würde. Wenn der Rumpf der Schleife etwa mit einer print-Anweisung beginnen würde, würde der Überlauf vor dem ersten Ausdruck gemeldet!

2) Ein Aufruf der Form

```
k := m+1;
n := 0
call tricky(a, b, n, m, k);
```

würde(hoffentlich) in der optimierten Version zu einer Fehlermeldung führen.
Die Originalversion würde dagegen korrekt arbeiten.

Um überhaupt Programmtransformationen vernünftig ansetzen zu können, muss erst einmal das Drei-Adress-Programm analysiert werden.

Ein möglicher Aufbau eines einfachen Codeoptimierers wäre:

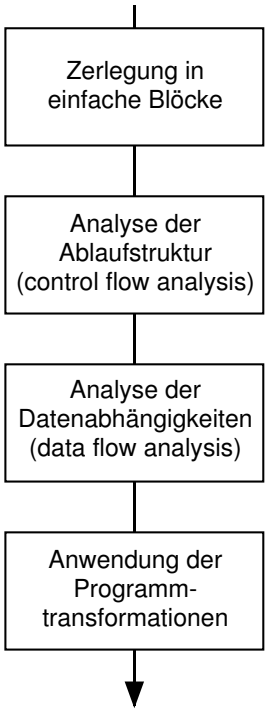

In der ersten Phase wird das Drei-Adress-Programm in sogenannte einfache Blöcke zerlegt. Ein einfacher Block ist dabei ein Teilstück, das garantiert vom ersten bis zum letzten Befehle sequentiell durchlaufen wird.
Die einfachen Blöcke bilden die Knoten eines gerichteten Flussgraphen. Dieser Graph wird in der nächsten Phase benutzt, um z.B. Informationen über die Ablaufstruktur zu sammeln. Es wird dabei auch versucht, Schleifen im Drei-Adress-Code zu identifizieren.
In der anschließenden Phase werden Definition und Verwendung von Variablenwerten in Beziehung gesetzt. Zum Beispiel interessiert vielleicht bei einem Drei-Adress-Befehl `a := b op c`, an welchen Stellen im Programm die hier benötigten Variablenwerte von `b` und `c` definiert wurden und ob deren Werte nach diesem Befehl noch an anderer Stelle benötigt werden. Typischerweise muss man, um derartige Fragen beantworten zu können, größere Gleichungssysteme (Datenfluss-Gleichungen) lösen. Dieses Schema ist relativ maschinenunabhängig und eignet sich daher für einen allgemeinen Codeoptimierer. Die einzelnen Phasen sind aber meist nicht so strikt getrennt, sondern für eine bestimmte mögliche Programmtransformation werden die dazu benötigten Informationen gesammelt und daraufhin entschieden, ob die Transformation durchgeführt wird. Häufig beschränkt man sich darauf, den Drei-Adress-Code einer jeden Prozedur getrennt zu optimieren.

6.2 Einfache Blöcke und Flussgraphen

Idee: Partitionierung der Drei-Adress-Befehle des Zwischencode-Programms in maximale, zusammenhängende Teile, die bei Ablauf des Programms immer sequentiell vom ersten bis zum letzten Befehl abgearbeitet werden müssen. Diese Teile werden **einfache Blöcke** genannt.

Beispiel 6.2:
Betrachte das folgende Fragment eines Drei-Adress-Programms:

```
        t1 := a + t1
L1:     t2 := a + c
        t3 := t1 * t2
        t4 := t3 + t1
        if t2 < t4 goto L1
        t1 := 2 * t4
```

Die Folge der Drei-Adress-Befehle vom 2. bis zum 5. Befehl bilden einen einfachen Block. Der 1. Befehl gehört nicht dazu, da andernfalls über die Marke `L1:` in den Block eingetreten werden könnte. Der 6. Befehl gehört ebenfalls nicht mit zu diesem Block, da nicht in jedem Fall nach dem 5. der 6. Befehl abgearbeitet wird.

6.2.1 Algorithmus zur Partitionierung in einfache Blöcke:

Eingabe: Eine Folge von Drei-Adress-Befehlen
Ausgabe: Eine Liste einfacher Blöcke; jede Anweisung befindet sich in genau einem einfachen Block.

Verfahren:

1) Zuerst wird die Menge der führenden Befehle in einem einfachen Block markiert.
   - i) Die erste Anweisung des Drei-Adress-Programms wird markiert.
   - ii) Jede Anweisung, die das Ziel eines bestimmten oder unbestimmten Sprunges ist, wird markiert.
   - iii) Jede Anweisung, die einem bestimmten oder unbestimmten Sprung oder einem Prozeduraufruf folgt, wird markiert.
2) Für jeden führenden Befehl besteht der zugeordnete einfache Block aus diesem Befehl und allen nachfolgenden Befehlen ausschließlich des nächsten markierten Befehls oder dem Ende des Drei-Adress-Programms.

6.2.2 Nächster Gebrauch oder der Lebendigkeit von Variablen

An dem obigen Beispiel kann man auch noch weitere wichtige Begriffe erläutern:

- Der 3. Befehl `t3 := t1 * t2` repräsentiert eine Position im Drei-Adress-Programm, an der die Variable `t3` **definiert** wird und an der die Variablen `t1` und `t2` **benötigt** (oder auch **gebraucht**) werden.
- Manchmal wird der Gebrauch einer speziellen Definition einer Variablen betrachtet. Im Beispiel wird im 3. Befehl die Definition der Variablen `t1` im 1. Befehl benötigt. Wichtig ist dabei, dass zwischen der Definition und dem Gebrauch keine Neudefinition von `t1` stattfindet.
- Ein Programm-Punkt im Drei-Adress-Programm charakterisiert eine Position vor oder nach einem Drei-Adress-Befehl.

- Am Programm-Punkt nach dem 4. Befehl ist die Variable `t1` **lebendig**, weil der Wert von `t1` an anderer, erreichbarer Stelle (in diesem Fall im 3. Befehl) im Programm benötigt wird. Die Erreichbarkeit ist natürlich nur hypothetisch und kann auch in einem anderen einfachen Block liegen. Man nimmt dabei also an, dass jede Alternative eines bedingten Sprungs auch möglich ist.
- Die Variable `t3` ist an diesem Programm-Punkt **nicht lebendig** oder **tot**, da kein weiterer Gebrauch von `t3` erreichbar ist.
- Auch hier kann man genauer von der Lebendigkeit einer speziellen Definition der Variablen sprechen. Am Programm-Punkt nach dem 4. Befehl ist die Definition der Variable `t1` im 1. Befehl lebendig. Die Definition von `t1` im letzten Befehl ist dagegen an diesem Programm-Punkt nicht lebendig

6.2.3 Konstruktion des Flussgraphen

Aus der Liste der einfachen Blöcke wird ein gerichteter Graph erzeugt, der den Kontrollfluss innerhalb des Drei-Adress-Programms berücksichtigt. Die einfachen Blöcke bilden die Knoten des Flussgraphen. Der Knoten, der den ersten Drei-Adress-Befehl enthält, wird als **Startknoten** ausgezeichnet.
Eine gerichtete Kante führt vom Knoten B_1 zum Knoten B_2, falls

1) es einen bedingten oder unbedingten Sprung vom letzten Befehl in B_1 zum ersten Befehl in B_2 gibt oder
2) der erste Befehl von B_2 im Drei-Adress-Programm unmittelbar nach dem letzten Befehl von B_1 folgt und der letzte Befehl in B_1 kein unbedingter Sprung ist.

Hinweis: In manchen Situationen ist es vorteilhaft, zwei zusätzliche, künstliche einfache Blöcke **entry** und **exit** dem Flussgraphen hinzuzufügen (**erweiterter Flussgraph**). Vom Block **entry** gibt es genau eine Kante zum ausgezeichneten Startknoten. Ferner führt eine Kante von jedem Block, über die der Flussgraph verlassen werden kann, zum Block **exit** .

Beispiel 6.3:
Betrachten wir das folgende Programmfragment mit der möglichen Übersetzung in Drei-Adress-Code:

```
begin                                    (1)  prod := 0
    prod := 0;                           (2)  i := 1
    i := 1;                              (3)  if i > 20 goto (14)
    while i <= 20 do                     (4)  t1 := 4 * i
        begin                            (5)  t2 := a[t1]
        prod := prod + a[i] * b[i];      (6)  t3 := 4 * i
        i := i+1;                        (7)  t4 := b[t3]
        end                              (8)  t5 := t2 * t4
end;                                     (9)  t6 := prod + t5
                                         (10) prod := t6
                                         (11) t7 := i + 1
                                         (12) i := t7
                                         (13) goto (3)
```

Man erhält folgenden Flussgraphen:

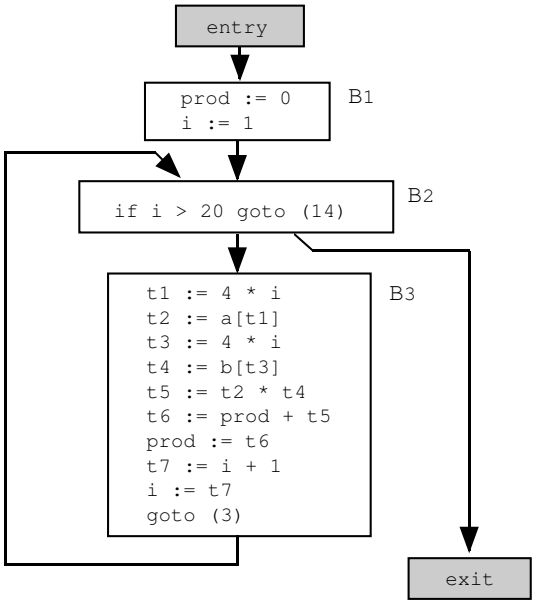

An diesem Beispiel ist auch zu sehen, dass es in dieser Darstellung zweckmäßig ist, als Sprungziele bedingter und unbedingter Sprünge die entsprechenden einfachen Blöcke zu verwenden.

6.3 Möglichkeiten der Codeoptimierung

Bevor die Methoden zur Analyse der Datenflussabhängigkeiten und der Ablaufstruktur genauer vorgestellt werden, soll zunächst einmal ein umfangreiches Beispiel (aus [1]) vorgestellt werden, dass die Möglichkeiten zur Codeoptimierung zeigt.

Beispiel 6.4:
Betrachtet wird eine Implementation einer Quicksort-Variante. Das zu sortierende Feld sei `a[0..max]`. Für jedes Teilfeld `a[m..n]` sei `a[n]` das Pivotelement.

```
void quicksort(m,n)
int m,n;
{
    int i,j;
    int v,x;
    if ( n <= m ) return;
    /* ab hier beginnt das betrachtete Codefragment */
    i = m-1;  j = n; v = a[n];
    while (1)  {
        do i = i+1; while (a[i] < v);
        do j = j-1; while (a[j] > v);
        if (i >= j) break;
        x = a[i]; a[i] = a[j]; a[j] = x;
    }
    x = a[i]; a[i] = a[n]; a[n] = x;
    /* hier endet das betrachtete Codefragment */
    quicksort(m,j); quicksort(i+1,n);
}
```

Für den oben bezeichneten Ausschnitt erhält man etwa das folgende Drei-Adress-Programm:

```
(1)     i := m-1                    (16)    t7 := 4*i
(2)     j := n                      (17)    t8 := 4*j
(3)     t1 := 4*n                   (18)    t9 := a[t8]
(4)     v := a[t1]                  (19)    a[t7] := t9
(5)     i := i+1                    (20)    t10 := 4*j
(6)     t2 := 4*i                   (21)    a[t10] := x
(7)     t3 := a[t2]                 (22)    goto (5)
(8)     if t3 < v goto (5)          (23)    t11 := 4*i
(9)     j := j-1                    (24)    x := a[t11]
(10)    t4 := 4*j                   (25)    t12 := 4*i
(11)    t5 := a[t4]                 (26)    t13 := 4*n
(12)    if t5 > v goto (9)          (27)    t14 := a[t13]
(13)    if i >= j goto (23)         (28)    a[t12] := t14
(14)    t6 := 4*i                   (29)    t15 := 4*n
(15)    x := a[t6]                  (30)    a[t15] := x
```

Der zugehörige Flussgraph wäre dann:

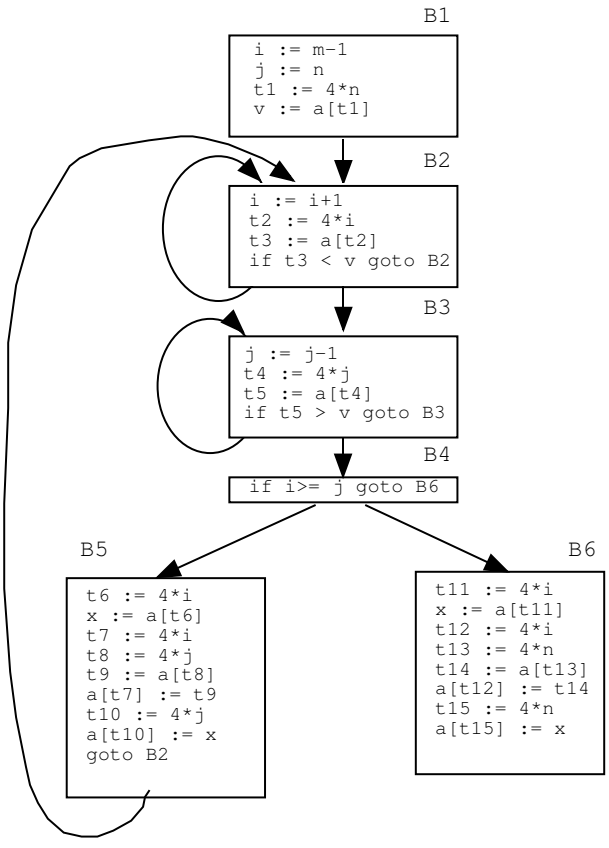

In `B5` werden die Ausdrücke `4*i` und `4*j` zweimal berechnet, in `B6` werden die Ausdrücke `4*i` und `4*n` ebenfalls zweimal berechnet. Wir haben also sogenannte **gemeinsame Teilausdrücke**, die natürlich nur einmal berechnet werden müssen. Da diese Optimierung sich nur auf jeweils einen einfachen Block bezieht, bezeichnet man diesen Vorgang auch als **lokale Entfernung gemeinsamer Teilausdrücke**.
Die beiden Blöcke werden also wie folgt umgeformt:

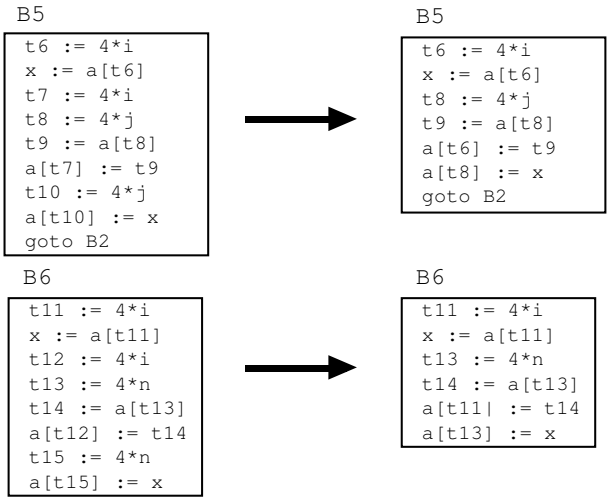

Nach der lokalen Entfernung gemeinsamer Teilausdrücke stellt man fest, dass die Berechnung von `4*j` in `B5` überflüssig ist, da dieser Term bereits in `B3` berechnet wurde und es keine andere Möglichkeit gibt, als über `B3` nach `B5` zu gelangen. Also kann man die drei Befehle `t8 := 4*j`, `t9 := a[t8]` und `a[t8] := x` durch die beiden Befehle `t9 := a[t4]` und `a[t4] := x` ersetzen. Damit ergibt sich aber der gemeinsame Teilausdruck `a[t4]` in `B3` und `B5`, also kann man `t9 := a[t4]` und `a[t6] := t9` ersetzen durch `a[t6] := t5`.
Der Block `B5` enthält jetzt die Befehle:

```
t6 := 4*i
x := a[t6]
a[t6] := t5
a[t4] := x
goto B2
```

Analog erkennt man jetzt den gemeinsamen Teilausdruck `4*i` in `B5` und `B2` und ersetzt die drei Befehle `t6 := 4*i`, `x := a[t6]` und `a[t6] := t5` durch `x := a[t2]` und `a[t2] := t5`. Danach wird wiederum `a[t2]` als gemeinsamer Teilausdruck erkannt und `x := a[t2]` durch `x := t3` ersetzt.
Die gleichen Überlegungen können für den Block `B6` angestellt werden und man erhält einen neuen Flussgraphen:

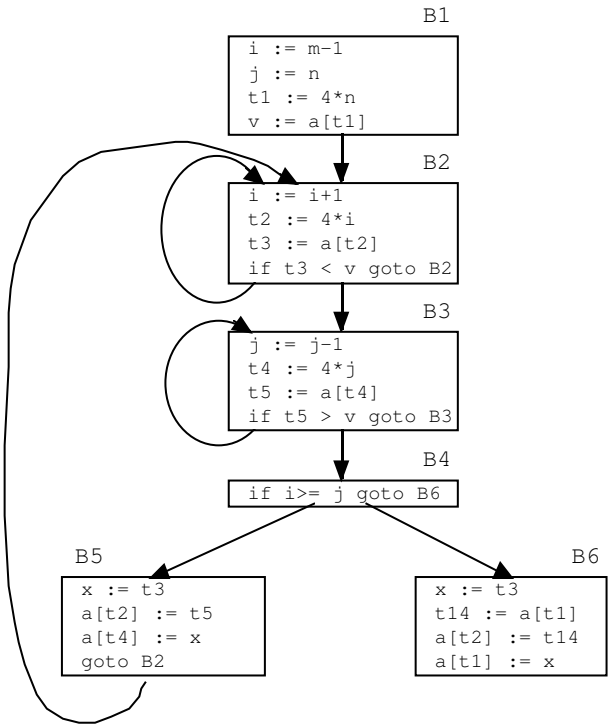

Achtung: Der Ausdruck `a[t1]` in `B1` und `B6` ist **kein** gemeinsamer Ausdruck! Auf dem Weg von `B1` nach `B6` kann der Block `B5` durchlaufen werden, in dem eine Wertzuweisung an das Feld `a` steht. Sofern keine weiteren Informationen zur Verfügung stehen, muss angenommen werden, dass **jedes** Element von `a` dadurch verändert wurde, also auch `a[t1]`!

Man sieht an diesem Beispiel, dass es unbedingt notwendig ist, Informationen über den Gebrauch und die Definitionen von Variablen auch über Blockgrenzen hinweg zu sammeln und mögliche Wege des Ablaufs im Flussgraphen zu berücksichtigen. Diese Probleme werden in den nächsten Abschnitten behandelt.

Neben der Erkennung und Entfernung gemeinsamer Teilausdrücke gibt es noch eine ganze Reihe weiterer Möglichkeiten, den Zwischencode zu verbessern.
Durch die Entfernung gemeinsamer Teilausdrücke werden häufig Anweisungen der Form `x := y`, sogenannte „Kopien“, eingeführt. Ziel einer weiteren Programmtransformation ist es, nach einer derartigen Anweisung soweit wie möglich ein auftretendes `x` durch `y` zu ersetzen. Man nennt diese Transformation auch das „Weiterreichen von Kopien“ (Copy Propagation).
In unserem Beispiel kann man in `B5` `a[t4] := x` durch `a[t4] := t3` und in `B6` `a[t1] := x` durch `a[t1] := t3` ersetzen.

Eine weitere Möglichkeit zur Codeverbesserung besteht darin, Befehle mit konstanten Operanden bereits zu diesem Zeitpunkt auszuwerten und die Ergebnisse ähnlich wie oben weiterzureichen. Beide Transformationen hinterlassen meist überflüssige Befehle. Ein Befehl ist überflüssig, wenn der einfache Block, in dem er auftritt, nicht vom Startknoten erreichbar ist oder aber wenn der Befehl von der Form `a := ...` ist und `a` nach diesem Befehl nicht lebendig ist. Überflüssige Befehle können ohne weiteres entfernt werden.

Eine weitere wichtige Programmtransformation ist das Erkennen und Verschieben schleifeninvarianter Berechnungen an den Schleifeneintritt. Das erste Problem hierbei ist das Erkennen von Schleifen und deren Eintrittspunkt im Flussgraph. Als nächstes sind die Befehle im Rumpf der

Schleife zu identifizieren, die bei jedem Durchlauf durch die Schleife den selben Wert berechnen. Dann müssen diese Befehle in einen einfachen Block vor dem Schleifenanfang ausgelagert werden.
Ein anderer Ansatz zur Schleifenoptimierung führt über das Erkennen von sogenannten „Induktionsvariablen“, das sind Variable, die sich bei jedem Schleifendurchlauf um einen konstanten Wert verändern. Häufig kann man diese Induktionsvariablen bis auf eine einsparen und dabei eventuell sogar eine „teure“ Operation (etwa eine Multiplikation) durch eine „billige“ (etwa eine Addition) ersetzen.
In unserem Beispiel werden im Block `B3` die Werte von `j` und `t4` synchron bei jedem Schleifendurchlauf verändert. Wird `j` um 1 vermindert, so wird `t4` um 4 vermindert. Entsprechendes gilt für die Werte von `i` und `t2` im Block `B2`. Letztlich ist es sogar möglich, im Block `B4` die Abfrage `if i >= j goto B6` durch `if t2 >= t4 goto B6` zu ersetzen, da `t2 = 4*i` und `t4 = 4*j` an dieser Stelle gilt. Damit werden die Variablen `i` und `j` in den Blöcken `B2` und `B3` überflüssig und man erhält:

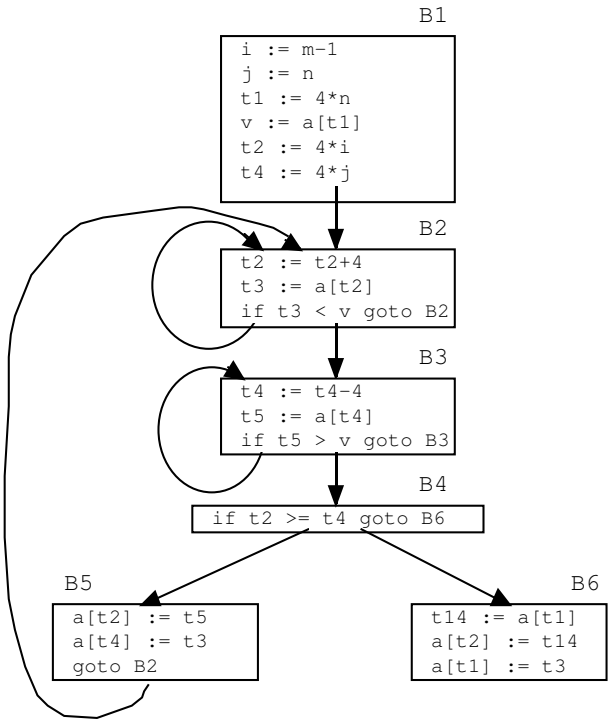

Es wären noch weitere Optimierungen in `B1` möglich, jedoch ist es fraglich, ob sich der Aufwand lohnt, da `B1` nur einmal durchlaufen wird.